

Proyecto final:

Implementación del algoritmo de clasificación supervisada por el vecino más cercano para la identificación de pelotas de goma de diferentes colores.

Walter Alejandro Moreno Ramírez
Departamento de Estudios Multidisciplinarios
Universidad de Guanajuato
Yuriria, Guanajuato
wa.morenoramirez@ugto.mx

Abstract—This article describes the implementation of the clustering algorithm by the near neighbor. The components of this method and how It can be implemented for the clustering of color balls, using their color feature.

Index Terms—Pixel, píxeles, umbralización, otsu, segmentación, distancia, clase, canal, promedio, vecinos, vecindario, color.

I. INTRODUCCIÓN

Los algoritmos de clasificación son una herramienta muy importante para detectar y analizar una serie de objetos presentes en una imagen, catalogados como clases; estas clases pueden ser desde un bosque, un cuerpo de agua, personas, carros o clasificar pelotas de goma. Las clases deben compartir características que de acuerdo al vecindario de los píxeles nos ayuden a clasificar cada objeto a una clase en específico. Existen dos algoritmos principales de clasificación: clasificación supervisada y la clasificación no supervisada.

Clasificación supervisada y no supervisada

Los algoritmos de clasificación supervisada son aquellos donde tenemos un conocimiento a priori acerca de la cantidad de clases y las características que las describen dados por un conjunto de elementos ya clasificados. Este algoritmo consta de dos etapas: entrenamiento, donde se obtienen los prototipos de las clases y pruebas, donde se toman nuevos elementos para clasificar.

Por el contrario, para la clasificación no supervisada no se posee este conjunto de elementos ya clasificado; en lugar de ello el algoritmo toma el conjunto de elementos de prueba y basandose en diferentes factores estadísticos, como lo es la media, los agrupa en clases distintas. Para este algoritmo el

único conocimiento a priori es el número de clases.

Para el presente proyecto se implementó la clasificación supervisada, la justificación en la elección de este algoritmo es debido a que se tiene el conocimiento de las distintas clases involucradas ya que son pelotas de diferentes colores y, como objetivo, se desea clasificar las distintas pelotas de acuerdo a sus características de color en tres clases diferentes que son: ClassRed 1 (pelotas verdes), ClassGreen 2 (pelotas rojas) y ClassBlue 3 (pelotas azules), aunque no todas las pelotas tienen el mismo color, la intención es observar a que categorías pertenece, por ejemplo, una pelota amarilla utilizando este algoritmo.

II. METODOLOGÍA

II-A. Etapa de entrenamiento

La primer etapa del algoritmo de clasificación supervisada consiste en el entrenamiento, en esta etapa se obtienen las características de todos los elementos (pelotas) que pertenecen a una misma clase, a este grupo de elementos se le conoce como conjunto de datos etiquetados. Este conjunto se puede apreciar mejor a manera de gráfica en un diagrama de dispersión como el de la Figura 1.

Posteriormente se calcula el promedio de las características de cada conjunto de datos etiquetados. Al final de la etapa de entrenamiento tendremos como resultado un prototipo para cada clase, en este caso será un promedio para cada uno de los tres canales de color de la imagen de entrada. Con esto tendremos definidas las tres clases y procederemos a la etapa de pruebas.




Figura 1: Ejemplo de un diagrama de dispersión para tres clases.

Imagen obtenida del sitio: www.teledet.com.uy/tutorial-imagenes-satelitales/clasificacion-supervisada.htm

II-B. Etapa de pruebas

La etapa de pruebas se debe realizar con elementos que no pertenezcan a los conjuntos de datos etiquetados que se utilizaron en la etapa de entrenamiento, esto para que el resultado sea justamente una prueba del algoritmo y la implementación ya que, de utilizarse un elemento perteneciente al conjunto de datos etiquetados para una clase en específico arrojaría un resultado esperado.

Para obtener la clasificación se utiliza el método por el vecino más cercano. Este método consiste en obtener la distancia euclidiana, utilizando la Ecuación (1) entre el elemento de prueba con cada una de las tres clases.

$$d = \sqrt{(R_p - R_{in})^2 + (G_p - G_{in})^2 + (B_p - B_{in})^2} \quad (1)$$

Donde:

- R_p, G_p y $B_p \rightarrow$ son los promedios de los canales Rojo, Verde y Azul respectivamente, del prototipo para cada clase.
- R_{in}, G_{in} y $B_{in} \rightarrow$ son los promedios de los canales Rojo, Verde y Azul respectivamente, de la imagen de entrada para las pruebas
- $d \rightarrow$ es la distancia entre el elemento nuevo y una de las tres clases.

Y su clasificación se hará con la distancia menor de las tres distancias calculadas ya que es a la clase que más se acerca de acuerdo a sus características de color. La Figura 2. muestra un ejemplo de esta etapa.




Figura 2: Ejemplo de la etapa de pruebas con un elemento nuevo 'a' para clasificarse con respecto al promedio de color de cada canal para las tres clases.

Imagen obtenida del sitio: www.teledet.com.uy/tutorial-imagenes-satelitales/clasificacion-supervisada.htm

III. RESULTADOS

Para realizar el proyecto se planteó un escenario donde existiera una banda transportadora que llevaría a cada pelota hacia una cámara a una altura definida que se encargaría de tomar fotos a cada pelota para segmentarlas del fondo y poder obtener las características de color de cada pelota ya sea en la etapa de entrenamiento o en la etapa de pruebas, para después clasificar la pelota en una de las tres clases que se definieron.

El sistema que se implementó se muestra en la Figura 3. donde se añadió a la banda transportadora una caja negra lo suficientemente grande para poder controlar las variables físicas como lo son la iluminación y la distancia entre la cámara y el objeto a fotografiar, esto con el fin de que las fotos resultantes no tuviesen algún defecto causado por el ambiente externo.



Figura 3: Caja negra implementada para controlar las variables físicas.

Como se puede apreciar en la Figura 3. la caja negra en la parte superior tiene un par de agujero, uno de ellos es para colocar una lámpara y el otro es para posar la cámara y que

pueda captar la imagen dentro de la caja negra con iluminación controlada. En la Figura 4. se muestra un ejemplo de una foto tomada para una pelota dentro de la caja negra.



Figura 4: Pelota dentro de la caja negra.

Para poder realizar toda la clasificación primero es necesario segmentar la pelota del fondo. Debido a que el fondo es negro y la pelota resalta fácilmente la mejor manera de segmentar la pelota es umbralizando la misma imagen pero en escala de grises, pero no todas las pelotas son del mismo color por lo tanto una umbralización con un valor fijo tendrá diferentes resultados con pelotas de distintos colores. Para solucionar esto se utilizó un umbral distinto para cada pelota, este umbral es el resultado del método de Otsu y al valor que nos da le sumamos 70 para obtener mejores resultados debido a que se obtienen muchos puntos que no pertenecen al objeto que necesitamos segmentar. El resultado de la umbralización para la imagen de la Figura 4. se muestra en la Figura 5.




Figura 5: Objeto resultante de la umbralización con un umbral dado por Otsu al que se le sumó 70.

Debido a que aún pueden existir objetos o píxeles pequeños que no pertenezcan al objeto deseado es necesario eliminarlos de la imagen, esto se logra aplicando morfología matemática, en específico fue necesario erosionar la imagen con un elemento estructural en forma de cuadro con dimensiones de 3 píxeles por lado, esto eliminaba esos objetos no deseados

pero también afectaba al objeto perteneciente a la pelota, para restaurar un poco su tamaño y forma es necesario dilatar la imagen con el mismo elemento estructural. El resultado de estas operaciones se ve en la Figura 6.




Figura 6: Objeto resultante al aplicar morfología matemática.

Al final es momento de separar el objeto de la imagen de entrada, el resultado se muestra en la Figura 7.



Figura 7: Pelota segmentada del fondo.

Al llegar hasta este punto cualquier pelota se puede segmentar y queda lista para su análisis de las características de color ya sea para la etapa de entrenamiento o la etapa de pruebas.

Se utilizaron tres pelotitas de goma de color Azul, Verde y Rosa (más parecida al rojo) para realizar la etapa de entrenamiento, y un grupo de tres pelotitas de colores Amarillo, Morado y Naranja para realizar la etapa de pruebas. Las pelotitas se muestran en la Figura 8.




Figura 8: Pelotitas para la etapa de entrenamiento (izquierda) y pelotitas para la etapa de pruebas (derecha).

Se definieron tres clases: *ClassRed*, *ClassGreen* y *ClassBlue*. Para obtener los prototipos de cada clase fue necesario obtener el promedio de cada canal de color de 10 fotos de muestra del mismo objeto en distintas orientaciones para cada uno de los objetos que se consideraron para el entrenamiento. Se utilizaron únicamente 3 elementos debido a que no se consiguieron más pelotas y con las que se contaban tenían un color uniforme, por dicha razón sólo se tomaron 10 muestras. Al finalizar la etapa de entrenamiento se obtuvieron los siguientes prototipos para cada clase:

$$\begin{aligned} \text{ClassRed} &= (255, 225, 230) \\ \text{ClassGreen} &= (206, 250, 209) \\ \text{ClassBlue} &= (194, 236, 254) \end{aligned}$$

Y de las cuales se obtuvieron las imágenes intermedias mostradas en la Figura 9. como parte de esta etapa de entrenamiento.




Figura 9: Imágenes intermedias obtenidas de la fase de entrenamiento para cada una de las clases.

La etapa de pruebas se realizó con las pelotas de la derecha mostradas en la Figura 8. Como resultado de las pruebas, en la Figura 10 se muestran las imágenes intermedias resultantes para las pelotas de prueba.



Figura 10: Imágenes resultantes de la segmentación para la etapa de pruebas. Pruebas con las pelotas de color Morado, Amarillo y Anaranjado.

Por consola se muestran varios datos sobre la clasificación. En primera, se muestran las distancias que se calcularon de la pelota entrante a cada una de las clases, esto nos da un parametro de medición de la exactitud con que se clasifica la pelota. Otro dato es el promedio de cada canal de la pelota de prueba, esto también nos ayuda a calificar si se realizó correctamente tanto la segmentación y el promediado de los datos como su clasificación.

Los resultados arrojados para la pelota de color Morado se muestran en la Figura 11.

```
Distancia a la clase roja -> 21.5881
Distancia a la clase verde -> 55.2503
Distancia a la clase azul -> 45.3385

Promedio de cada canal de color =
Rojo = 239.22
Verde = 235.632
Azul = 250.744

-----
**** BOLA ROJA ****
-----
```

Figura 11: Datos resultantes de la clasificación para la pelota color morado.

Podemos observar que la pelota fue clasificada como roja, es una sorpresa ya que a primera instancia no se puede apreciar una similitud entre ambos colores pero si observamos el promedio de cada color de la imagen de entrada, correspondiente a la pelota morada, y lo comparamos con el prototipo para la clase *ClassRed* podemos observar que el valor absoluto de la diferencia entre los promedios es (15,78, 10,62, 20,74) lo que produce que la distancia a esta clase sea la más costosa y se clasifique como una pelota Roja.

```

Distancia a la clase roja -> 138.969
Distancia a la clase verde -> 102.789
Distancia a la clase azul -> 147.889

Promedio de cada canal de color =
Rojo = 247.279
Verde = 235.138
Azul = 116.044

-----
**** BOLA VERDE ****
-----

```

Figura 12: Datos resultantes de la clasificación para la pelota color amarillo.

De acuerdo a la imagen de la Figura 12. para el caso de la pelota color amarillo, ésta es clasificada como una pelota verde, nuevamente observemos los datos que arroja la consola, mas específicamente los promedios de cada canal de color de la imagen correspondiente a la pelota amarilla y realizamos el mismo procedimiento que con la pelota morada, obtenemos el valor absoluto de la diferencia entre cada promedio de color, lo que da como resultado (41,27, 14,86, 92,96) y que nos asegura que la distancia era mínima entre las características de color de la imagen de entrada y la clase ClassGreen.

```

Distancia a la clase roja -> 71.4059
Distancia a la clase verde -> 56.5097
Distancia a la clase azul -> 89.966

Promedio de cada canal de color =
Rojo = 252.6
Verde = 227.531
Azul = 186.264

-----
**** BOLA VERDE ****
-----

```

Figura 13: Datos resultantes de la clasificación para la pelota color anaranjado.

Como podemos observar en la Figura 13. nos arroja los resultados tanto de clasificación como de promedios y distancias. Con estos datos y siguiendo el mismo procedimiento podemos obtener el valor absoluto de las diferencias entre cada promedio de colores, lo que resulta (46,6, 22,47, 22,74) y nos ayuda a comprobar el resultado de la clasificación como pelota verde.

IV. CONCLUSIONES

EL proyecto en un inicio pretendía implementarse en una banda transportadora en movimiento y con un sistema de control que estuviese conectado y realizando acciones de acuerdo a los resultados arrojados por el algoritmo de segmentación, esto no se pudo realizar debido a que surgieron errores al momento de implementar la transformada de Hough para detectar círculos, estos errores consumieron mucho tiempo además de que su implementación era muy tardada. Con estos errores se fue consumiendo el tiempo y la parte electrónica encargada del control no se implementó y se dió prioridad a la programación del algoritmo para segmentar la pelota del fondo y el propio algoritmo para la clasificación.

Hay muchos aspectos a mejorar, entre los que se incluyen mejorar el sistema para la obtención de imágenes, tanto la caja negra como la iluminación. Otro aspecto a mejorar es aumentar el número de clases y realizar la etapa de entrenamiento con un número más variado y suficiente de muestras y de igual manera la etapa de pruebas. Lo anterior para poder clasificar una mayor cantidad de pelotas y obtener un mayor grado de exactitud al clasificar.